

benchmark 主表

请师兄定方向

2026-09-17 · 12 个真实病例 · 四个系统跑在同一批文档上 · 本轮花费约 \$2.1

一句话：主表跑出来了，但修正两处度量缺陷之后，结论反过来了。

三种问法在"可验证性"上分不出来——引用、时间都是 100%，值 99~100%。唯一稳定的差别是有些大病例系统根本跑不出来。

我上一版报的"上下文一变、时间接地掉到 58.6%"，是我自己提示词的毛病，不是模型的错，已经撤掉。

01 主表

只比 laboratory_observations（检验观测）这一张表，同一批文档，同一个评分器。文档里实际有多少行用几何方法算出来（见第 03 节），12 个病例合计 2518 行。

系统	模型 调用	引用 可解析	值接地 逐字 / 数值归一化	时间 接地	跑通 病例	行数恢复 (只算跑通的)	成本
规则/几何 (不用模型)	0	100%	100% / 100% (注※)	99.5%	12/12	100% (注※)	\$0
整病例一次问	12	100%	87% / 99%	100%	9/12	88%	\$0.84
同类文档合并一次问	12	100%	88% / 100%	100%	8/12	93%	\$0.53
逐文档分开问	14	100%	86% / 100%	100%	9/12	76%	\$0.60

※ 规则法的字段是从它引用的那个格子里抄出来的，接地为真是构造保证，所以它只能证明"度量没坏"，不能证明它比模型强。

02 结论：三种问法分不出来，真正的问题是跑不出来

修掉两处缺陷之后（第 04 节）：引用 100%、时间 100%、值 99~100%，三种问法都一样。

唯一稳定的差别是"有些病例系统根本跑不出来"：

系统	跑不出来的病例	表现
规则/几何	0	——
整病例一次问	3 / 12	CASE-02、CASE-06、CASE-100
同类文档合并	4 / 12	CASE-02、CASE-06、CASE-09、CASE-100
逐文档分开问	3 / 12	CASE-02、CASE-04、CASE-100

失败的表现是**返回的 JSON 被截断、解析不了**，不是"抽得少"。CASE-100 的文档里实实在在写着 **514 行**检验结果，一次调用根本吐不完。把输出上限从 16000 提到 64000 后重跑，CASE-02 从 0 行恢复到 286 行（真值 290）、CASE-09 从 0 行恢复到 291 行（真值 293）——**一恢复就是 98% 的准头**。

这一格必须和"抽得少"分开看：把跑不出来的病例算成 0 分，行数恢复是 **40~48%**；只算跑通的，是 **76~93%**。两种算法差一倍，混在一起会得出完全相反的结论。

而且失败的病例每次跑不一样。同样配置再跑一次，CASE-04 从"正常 147 行"变成"跑不出来"，CASE-09 从"291 行"变成"10 行"。所以"跑通病例数"这一格本身也有噪声。

03 行数真值（还没修好的一格，不敢用）

做法是几何的：每页把格子横坐标做直方图，连续密集的一串算一列；**值列**是那一列里六成以上是纯数字、且位置在页面中右部（这样最左边的"序号列"不会被误选）。再按纵坐标把值格聚成行，聚出多少簇就是多少行。12 病例得 2518 行。

但逐病例一看就知道它还不能信：

病例	几何真值	整病例	同类合并	逐文档
CASE-01	91	111 (122%)	111 (122%)	111 (122%)
CASE-03	200	127 (64%)	128 (64%)	127 (64%)
CASE-05	139	141 (101%)	142 (102%)	143 (103%)
CASE-10	80	76 (95%)	75 (94%)	77 (96%)
CASE-101	144	144 (100%)	144 (100%)	144 (100%)

CASE-103	126	122 (97%)	122 (97%)	122 (97%)
----------	-----	-----------	-----------	-----------

CASE-01 是 122%——模型抽出来的行比"文档真值"还多，说明这个真值至少在那一个病例上漏数了；CASE-03 三种问法都稳定在 64%，也可能是真值多算了。→ **"行数恢复率"这一列要等真值校准完才能用。**

04 指标口径

值接地：以「数值相等」为主口径

判定规则是去掉尾零、千分位、前导零之后比较。

主口径下 **99~100%**；逐字口径下 82~88%，**差的 12~14 个点全部是尾零/千分位/前导零**，且全部出现在模型自己引用的那份文档里——这是格式差异，不是编造，所以逐字口径只作脚注。

时间接地：`time_refs` 允许指向多行

报出的时间必须逐字出现在它引用的 `time_refs` 行里。

实测依据：538 个时间对不上的行里，**302 行所在的文档中没有任何一行同时含日期和时刻**。所以 `time_refs` 必须允许指向多行（日期一行、时刻一行）——和 `source_refs` 是「证据集合」同一类设计。

引用可解析率作第一道闸

引用的行号必须真实存在。**这一闸不过，其余指标全部无效**（输出被截断时最先失效）。

05 请师兄定的事

① 主表现在是这样，行不行？

行：规则 → 整病例 → 同类合并 → 逐文档。列：引用可解析 / 值接地（逐字+归一化） / 时间接地 / 跑通病例数 / 行数恢复 / 成本。另外把"跑不出来"单列了一列。

② 现在三种问法分不出来，这个方向还能不能做？

主表现在的信息量基本只有一条：**好的契约下，前沿模型的抽取是可追溯的**；真正的失败是工程性的（大病例吐不完），不是能力性的。

这算不算一个能讲的结果？还是说要换角度（比如把规模铺到 200 病例、把 16 张表全做、换更难的题）？

③ "行数恢复率"要不要现在就报？

几何真值还没校准（CASE-01 出现 122%）。我倾向于先校准、暂时不报，或者只报"跑通/跑不出来"。

④ 要不要为了"能分开系统"去加难度？

现在分不出来，可能是因为任务对前沿模型太简单。可选：换成用药表/诊断表（时间在行内，更难）、加大病例规模、或者用更难的问法。想听你的判断。

06 还没做的（不遮掩）

- 16 张事件表**只做了 1 张**。检验表是唯一有稳定网格结构的；用药表、诊断表的时间在行内不在页脚。
- 规模只有 **12 个病例**（池子里有 200 个）。
- **只测了一个模型**（最便宜的那个）。
- 几何真值**没校准**，所以"行数恢复"这一列还不能用。
- 为什么大病例跑不出来知道是输出预算，但**为什么每次失败的病例不一样**没查。
- 内容正确率**做不了**（没有医生金标准）。本表所有格子都是机械可算的"可验证性"，不是"答得对不对"。

数据：治理后的 200 病例池，本次用 12 个。原始 PDF、OCR 正文、身份映射留在受控环境，本汇报只有匿名聚合数。

模型：`[j]gemini-3-flash`，温度 0，`max_tokens` 16000。总控面板 `CONTROL_PANEL.md`。