

EHR 事件表示与查询 Harness

阶段汇报

2026-09-15 · 真实三甲医院 PDF 数据 · 目标: KDD 2027 Cycle 2

一句话: 我们把"事件表示 + 查询 Harness"落到真实数据上做了一轮实测，**结果是负面的——我们自己提出的方法没有用，前沿模型本身已经做对了。** 现在把实测结论和缺口摆出来，请您指一个方向。

01 最重要的一个实测结果（必须放最前面）

模型 10 次调用，10 次全对。

我们用真实数据构造了一个任务：同一份病例的 **11 页检验报告只对应 2 次采血**（两次采血分别产生了 7 份和 4 份报告，分属 8 种不同报告类型——每页页脚都印着"采集时间"，精确到秒，同一次采血的几份报告全挤在十几秒以内）。

问 5 个前沿模型"这位患者有几次独立采血、哪些页属于同一次"：

10 次调用（5 个模型 × 2 次重复）全部答对，事件数都报 2，分组与真值完全一致，而且都正确引用了"采集时间"，**没有一例把报告时间当成采样时间**。连最便宜的模型也对。总成本不到 1 美元。

结论: 当正确答案在数据里显式存在时（页脚就印着采集时间），模型不需要任何"方法"就能读对。**我们原计划的那套机制在这个任务上收益为零。**

02 已经确认的事实（这些是可以复用的资产）

项	内容
数据规模	39,560 个病例目录 / 462,789 份 PDF。其中 200 例已完成治理 ，带 OCR 版面坐标、文档类型标签、脱敏记录。每例 5-18 份 PDF，中位 11 份。
文档类型覆盖	医嘱/申请 200 例、检验报告 187 例、医嘱执行 195 例、病程记录 200 例、影像报告 180 例、病理报告 122 例。

检验报告结构	每页六列：项目名称 / 缩写 / 结果 / 单位 / 参考区间 / 检测方法。页脚有 四个带标签的时间 ：采集时间 / 接收时间 / 报告时间 / 打印时间。表格内 没有行级时间、没有行级标本号 ，时间与编号只在页级。
实例数 ≠ 文档数	11 页报告 = 2 次采血，差 5.5 倍 。这个数不是文档数的函数。
脱敏是合格的	脱敏把绝对日期换成"相对日 + 偏移"， 时分秒原样保留 ，同一患者内的时间间隔也保留——做法标准且正确。
唯一还没被否证的	病程记录引用检验结果时写的是 [检验组合名][日期]，而检验报告里写的是具体项目名与缩写， 两种写法精确命中 0/50 。同一份检验有两套命名。是否因此导致重复计数， 还没测 。

03 我们这两天否证了自己三次

提过的方向	怎么被否决的
①事件身份 已否决	副本 vs 真实复测的判定。实测 10/10 全对，无方法收益。
②嵌套 Harness 已否决	对抗审稿的判决："把标题和正文里的 Harness 全部换成 pipeline，内容一字不变"——框架是装饰性的，不是机制。
③发布确定性 已否决	假设"脱敏之后就算不出采血次数了"。实测：脱敏保留了时分秒，计数依然完全确定，假设不成立。

还有一件事要主动汇报：此前汇报过的那些指标（F1 从 0 提升到 1.0 等），经审计发现是"手写答案对手写答案"的自洽检查，模型调用次数其实是 0。这些已经从面板上全部撤下来了。项目历史上第一次真实的大模型调用，就是上面那次 10/10 的测试。

04 同时确认：几条常见路线已经被别人做了

方向	已被谁占
文档数 ≠ 临床事件数 / 计数工具	arXiv 2608.31017
把检验结果链接到它的"检验事件"	CLinkaRT / TESTLINK（2023 年就有共享任务）
临床事件的时间锚定与来源裁决	arXiv 2609.13062、2605.15168
OCR 临床报告的结构化抽取	MedStruct-S（KSEM 2026）、Key Coverage Matters
Harness 效应 / 编排对比	DataSpace、Harness-Bench
Agent 预算与成本控制	arXiv 2511.17006（COLM 2026）
上下文治理与溯源	ContextNest、Eywa

05 所以我们现在真正缺的是什么

不缺数据、不缺算力、不缺执行力。缺的是"哪个临床问题真的重要"这一层判断。

我们手里已经有一批"数据实际上是什么样"的硬事实（上面第 02 节），但我们不知道

这些事实里哪一条对科室是真痛点。这两天连续否认三次的根本原因就在这里—— 我们在用自己的猜测去替代临床判断。

06 想请您判断的三个问题

- ① 病程记录和检验报告对同一份检验用**两套名字（精确命中 0/50）**——这在科室里是真问题吗？ 会不会真的有人把一次检验数成两次？
- ② 临床上真正需要**"把散在多份文档里的信息拼起来才能回答"**的问题，具体是哪几个？ 您或同事日常真会遇到的，举两三个就够。
- ③ 如果模型读单份文档已经足够准了，那在您看来，**这套系统还差什么才算真正有用？**

07 投稿计划（请您确认）

会议	大致截稿	说明
CVPR 2027	2026 年 11 月	您说时间特别适合。但 CVPR 偏视觉，我们的临床文档任务需要重述定位， 需要您判断能不能落进去。
KDD 2027 Cycle 2	约 2027 年 2 月 (官方未公布)	主线目标，你已确认要投。
IJCAI 2027	约 2027 年 1 月	您提到的"yijieka"，我猜是 IJCAI（口语常读"艾杰卡"）——但 IJCAI 是 CCF-A，您说是 B 会， 可能是另一个会，请确认名字。
MICCAI 2027	约 2027 年 2-3 月	您说之前记的 MICAD 有问题，应为 MICCAI。
ACM MM 2027	约 2027 年 3-4 月	您说希望比较大。

以上除 KDD 外，具体日期我还没逐条核官方 CFP，会在您确认赛道后补齐。

08 最近一周打算怎么走（小步快跑）

- 每天一次极短同步：**一句进展 + 一个数字 + 一个卡点，不再攒成大汇报。
- 动手前先花半天测：**任何一个"系统会犯错"的判断，先在一个模型上实测再报，不再靠推理下结论。
- 立刻可做的一件事**（不需要新授权、成本不到 1 美元）：在整份病历上问模型"某项目测了几次"，看它会不会把病程记录的引用和检验报告的行**重复计数**。这验证第 02 节最后那条

唯一未被否证的线索。

仓库与面板（您可以让 AI 直接读仓库回答追问）：

- 总览面板：dashboard.html · 总控面板：CONTROL_PANEL.md · 论文 Proposal：paper/PROPOSAL.md
- 三份关键实测记录：results/2026-09-14_model_event_test.md（10/10 那次）、results/2026-09-14_truth_audit.md（真伪审计）、results/2026-09-14_event_identity_finding.md
- 选题调研与对抗审查：paper/KDD_IDEA_2026-09-14.md

本页所有数字都来自真实数据上的可重跑脚本，未取任何患者正文。患者原始数据、OCR 正文与参考答案全部留在受控环境内。