

EHR 事件表示与查询 Harness

阶段汇报

2026-09-15 · 真实医院 PDF 数据 · 目标会议: KDD 2027 (另考虑 CVPR / MICCAI / ACM MM)

一句话: 我们试了十几个方向, 一个都没成。

我们自己提了三个方案, 用真实数据一测, 全都不成立。这页把结果摆出来, 请您指个方向。

01 最要紧的一个结果

让模型数抽血次数: 跑 10 次, 对 10 次。

我们拿一个真实病例, 11 页检验报告, 问模型"这个病人抽了几次血、哪些页是同一次"。

答案其实就印在页脚。每页都有"采集时间", 精确到秒。7 页挤在十几秒内, 是同一次抽血; 另外 4 页在另一天, 是另一次。所以正确答案是 2。

5 个模型各跑 2 遍: **10 次全部答对**。都说 2 次, 分组跟我们算的一模一样, 引用的也都是"采集时间", **没有一个把报告时间当成采样时间**。连最便宜的那个模型也全对。一共花了不到 1 美元。

这说明什么: 只要答案在文档里明明白白写着, 模型不需要我们做任何东西就能读对。 **我们原来计划的那套方法, 在这个任务上没有用武之地。**

02 手里有什么

东西	情况
数据	3.96 万个病例目录、46 万份 PDF。其中 200 个病例已经治理完 : OCR 文字带坐标和置信度, 每份文档标了类型, 还做了脱敏。每个病例 5 到 18 份 PDF, 一般 11 份。
文档类型	200 个病例里: 医嘱 200、病程记录 200、入院记录 200、检验报告 187、医嘱执行 195、出院记录 196、影像报告 180、病理报告 122。

检验报告长什么样	每页一张表，六列：项目名称、缩写、结果、单位、参考区间、检测方法。页脚有四个时间：采集时间、接收时间、报告时间、打印时间。 表格里面没有时间，也没有标本号，时间和编号都只在页级。
脱敏流水线	已经跑通，而且做得对：绝对日期换成"相对日 + 偏移"，时分秒保留，同一个病人内部的间隔也保留。
代码	评分器和几个小模块，都只在编造的合成数据上跑过。 真实数据上一条合格结果都没产出过。
模型通道	已经打通：在受控主机上跑，只有提问发出去，数据不外流。跑一次实验不到 1 美元。

03 试过的方向，和为什么不行

方向	怎么了
EHR 治理评估 缺失值怎么表示 影像模型复现 (8 月底)	做了一阵就停了，或者条件没到位（需要更高权限的数据和人工标注）。文件里没写详细原因，是我们自己放弃的。
①事件身份 (判断两份记录是同一次抽血还是两次)	不行。 就是上面第 01 节那个测试：模型 10 次全对，我们这套东西用不上。
②嵌套 Harness (外层管跨文档，内层管单文档)	不行。 我们让一个审稿角色来挑刺，它说：“把标题和正文里的 Harness 换成 pipeline，内容一个字都不用改。”也就是说这个框架是摆设。
③脱敏之后算不出来	不行。 我们猜脱敏把日期抹了，抽血次数就数不出来了。一对比发现猜错了：四个时间标签全在，绝对日期换成了“相对日 + 偏移”，但时分秒一个没动，照样能数。
其余几个 (证据会计、擦除后审计、可判定性分级等)	只是想法，还没测。
两个地方名字对不上	这条还活着。 病程记录里引用检验结果写的是“[检验组合名][日期]”，检验报告里写的是具体项目名和缩写，两边 一条都对不上 (0/50) 。 但是“会不会因此把一次检验数成两次”，我们 还没测 。

还有一件得主动说的事。 之前汇报过的成绩 (F1 从 0 涨到 1.0 之类) ，后来查出来是**拿手写的答案去对另一份手写的答案**，模型调用次数其实是 0。这些已经从面板上全撤了。**这个项目第一次真的调用大模型，就是上面第 01 节那 10 次。**

04 别人已经做过的，别再投了

我们本来想做的	别人做过了
数事件不数文档	arXiv 2608.31017，标题级主张已经被拿走了
把检验结果对到它那次检验	CLinkaRT / TESTLINK，2023 年就有共享任务

临床事件的时间锚定	arXiv 2609.13062、2605.15168
从 OCR 临床报告里抽结构化数据	MedStruct-S (2026) 、Key Coverage Matters
把 OCR 噪声当成输入信号	ICML 2026 workshop, 连这个小改进都有人做了
比较不同编排框架的效果	DataSpace、Harness-Bench
控制 Agent 的花费	arXiv 2511.17006 (COLM 2026)
可验证的上下文管理	ContextNest、Eywa
答案要有出处	ACIE (2606.19602) : 实测幻觉引用 0.0%, 说明这不是瓶颈

05 所以我们缺什么

不缺数据，不缺算力，不缺人手，不缺代码。

缺的是：哪个临床问题真的重要。

上面那些方向里，真正"动手测过才发现不行"的只有 3 个，剩下大多是我们自己猜的，本来就不重要。昨天一天连错三次，根子就在这：我们在拿猜测代替临床判断。

06 想请您定的三件事

1. 病程记录和检验报告对同一份检验用了两套名字，一条都对不上。**这在科室里算问题吗？真**
会有人把一次检验数成两次吗？
2. **临床上哪些问题必须把好几份文档拼起来才能回答？** 举两三个您或同事日常真遇到的就行。
3. 如果模型读单份文档已经够准了，**那这套系统还差什么才算有用？**

07 投稿安排（想请您确认）

会议	截稿	说明
CVPR 2027	2026 年 11 月	您说时间特别适合。但 CVPR 偏视觉，我们的任务是临床文档， 需要您判断能不能落进去。
KDD 2027 Cycle 2	2027 年 2 月左右 官方还没公布	主干目标。

IJCAI 2027	2027 年 1 月左右	您说的"yijieka", 我猜是 IJCAI。但 IJCAI 是 CCF-A, 您说是 B 会, 可能是另一个会, 想请您确认名字。
MICCAI 2027	2027 年 2 到 3 月	之前记成 MICAD 了。
ACM MM 2027	2027 年 3 到 4 月	您说希望比较大。

除 KDD 外, 上表日期我还没逐个查官网, 等您定了主攻哪个我立刻补上。

08 接下来打算怎么走

- **每天跟您同步一句**: 做了什么、看到一个什么数、卡在哪。不再攒成大汇报。
- **动手前先花半天测**。任何"系统会犯错"的判断, 先在一个模型上跑一遍再报给您, 不靠推理下结论。
- **马上能做的一件事** (不用新授权, 不到 1 美元): 在整份病历上问模型"某项目测了几次", 看它会不会把病程记录的引用和检验报告的行**算成两次**。这就是上面那条唯一还有希望的线索。

仓库和面板 (可以让 AI 直接读仓库回答追问):

面板: `dashboard.html` 试过什么: `attempts.html` 总控: `CONTROL_PANEL.md` Proposal: `paper/PROPOSAL.md`

实测明细: `results/2026-09-14_model_event_test.md` (那 10 次调用)、`results/2026-09-14_truth_audit.md` (真伪审计)

这页所有数字都来自真实数据上能重跑脚脚本。患者原始数据、OCR 正文和参考答案全部留在受控环境里, 没有进仓库。