

benchmark 主表跑出来了

请师兄定四件事

2026-09-17 · 12 个真实病例 · 四个系统跑在同一批文档上 · 花费约 \$4.8

一句话：按你说的"先把任务的输入输出定死再比"，我们把主表跑出来了。

四个系统、同一批文档、同一套评分器。结论是引用可解析率这一列谁都满分、分不出系统，真正能分开系统的是时间落地和行数恢复。另外撤回了上一版一个错数字。请师兄定口径。

01 主表

只比 laboratory_observations（检验观测）这一张表，每个病例抽同样的文档，评分器同一个。文档里实际有多少行，用几何方法算出来（见第 03 节），12 个病例合计 2518 行。

系统	模型调用	输出行数	引用可解析	值接地逐字/归一化	时间接地	报了病例里不存在的时间	状态码	成本
规则/几何 (不用模型)	0	2518 100%	100%	100% / 100% (注※)	99.5%	0	1/9	\$0
整病例一次问	12	1300 52%	100%	82.4% / 98.9%	58.6%	464 行 (36%)	1/9	\$0.94
同类文档合并一次问	12	1025 41%	100%	85.2% / 99.7%	100%	0	1/9	\$0.50
逐文档分开问	14	1617 64%	100%	84.3% / 99.8%	100%	0	1/9	\$0.76

※ 规则法的字段是从它引用的那个格子里抄出来的，接地为真是构造保证，所以它只能证明"度量没坏"，不能证明它比模型强。

另外要看的：有些病例系统根本跑不出来——整病例一次问有 3/12 个病例吐不出可解析的 JSON，同类合并 4/12，逐文档 2/12。这些病例的输出是 0 行，现在被算进上表的行数里了。

02 三条结论

结论 1：引用可解析率已经废了

三个模型设置、3942 行，引用可解析率全部 100%。现有临床抽取评测报的就是这个指标（ACIE 报 hallucinated reference 0.0%）。它已经饱和，分不出系统好坏。

结论 2：能分开系统的是时间落地

同一个模型、同一个输出上限、同一批文档，只换了上下文范围：整病例一次问时间接地 58.6%，同类合并和逐文档都是 100%。

那 464 行不是格式差异，是完整的年-月-日，而这个"年-月-日"在整份病例里一次都没出现过（比的是数字序列，所以"2024年3月5日"和"2024-03-05"算同一个）。而它的引用还是 100% 可解析。

这是本次最值钱的一格：引用存在性检查看不见这一类错。

两次整病例运行，报出病例里不存在的时间的比例是 24% 和 41%，都远高于 0。

结论 3：撤回上一版一个错数字

上一版我报"13% 的数值在整份文档里找不到"。这次查明是我自己造的假象：输出上限设成 8000 太小，模型吐到一半被截断。同一配置提高到 16000 之后，那个数字就没了。

重测 3926 个值：逐字接地 82~85%，按数值归一化后 98.9~99.8%，逐字不接地的 633 处没有一处是"整份病例里连子串都找不到"。

逐字不接地的原因	数量	出现在哪
尾零 / 小数位不同	421	模型自己引用的那份文档
千分位、空格等格式差异	163	模型自己引用的那份文档
前导零	48	模型自己引用的那份文档
前缀截断	1	模型自己引用的那份文档

值这一层没有编造，编造发生在时间这一层。（其中 21 处全文找不到数值相等的数字，只在同一份文档里以"更长数字的子串"形式出现，相当于取整。）

03 行数真值是怎么算的

不用人工数。每页把格子的横坐标做直方图，连续密集的一串算一列；**值列**就是那一列里六成以上是纯数字、且位置在页面中右部（这样最左边的"序号列"不会被误选）。然后按纵坐标把值格聚成行，**聚出多少簇就是多少行**。

12 个病例算下来 2518 行。跟模型对照：CASE-05 几何 139 / 模型 141；CASE-06 几何 330 / 模型 315；CASE-09 几何 293 / 模型 291。没找到值列的 75 页平均只有 50 个格子、其中纯数字占 4%，是纯文字页，不是漏行。

要说明的是：这不是医生金标准，是"文档结构上确实有多少行"。它可以逐页复算，但没有人逐行核对过。

04 请师兄定四件事

① 主表的行列就按上面这样定，行不行？

行的顺序：规则 → 整病例 → 同类合并 → 逐文档。列就是那九列。

② "值接地"用哪个口径？

问题：同一份输入重跑三遍，值接地是 **95% / 95% / 84%**，跳 11 个点。引用和时间都是 100%/100%/100%，纹丝不动。

原因：文档写 5.60，模型抄成 5.6 判接地，抄成 5.60 也判接地；但文档写 5.6、模型写 5.60 就判不接地。小数位写法一变，百分比就跳。

三个选项：报区间（"84%，三次 95/95/84"） / 跑多次取平均（成本翻 3~5 倍） / 换成"数值相等"口径（98.9~99.8%，三遍基本不跳，但抓不到格式差异了）。

③ "系统级失败"要不要单列一列？

具体例子：CASE-100 的文档里实实在在写着 **514 行**检验结果。整病例一次问时模型要一次吐出 514 行 JSON，输出上限装不下，返回断掉的 JSON → 这个病例最后是 **0 行**。它把这行整体拉低约 20 个点。

但："抽了 50 行、漏了 464 行"是**抽取能力**问题；"一个字都没吐出来"是**系统跑不完**。

混在一列，看表的人会以为系统抽得不全，其实是根本没跑出来。把上限提到 64000 后，CASE-02 从 0 行变 286 行（真值 290）、CASE-09 从 0 行变 291 行（真值 293）——

一恢复就是 98% 的准头，说明它本来抽得出来。

建议：拆成"跑通病例数 / 总数"和"跑通病例上的行数恢复率"两列。

④ 拿几何真值当"行数恢复率"的分母，行不行？

它不是医生金标准。要不要只当辅助列，主指标换成别的？

05 还没做的（不遮掩）

- 16 张事件表**只做了 1 张**。检验表是唯一有稳定网格结构的；用药表、诊断表的时间不在页脚而在行内，得逐表定规则。
- 规模只有 **12 个病例**（池子里有 200 个）。
- **只测了一个模型**（最便宜的那个）。
- "为什么上下文一变，模型就开始编时间"——**机制没解释**，只知道现象稳。
- 内容正确率**做不了**（没有医生金标准）。本表所有格子都是机械可算的"可验证性"，不是"答得对不对"。

数据：治理后的 200 病例池，本次用 12 个。原始 PDF、OCR 正文、身份映射留在受控环境，本汇报只有匿名聚合数。
模型：`[j]gemini-3-flash`，温度 0，`max_tokens` 16000。本次花费约 \$4.8（含几次失败的尝试；主表那一轮约 \$2.2）。

完整实测记录在仓库 `results/2026-09-17_main_table.md`；总控面板 `CONTROL_PANEL.md`。